Verdade Digital: Estudo sobre Fake News em Vídeos no YouTube voltados ao público infanto-juvenil

Henrique M. de Sousa Belo[1], **Humberto T. Marques Neto**[1]

[1]Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Caixa Postal 1.686 – 30.535-901 – Belo Horizonte – MG – Brasil

hbelo@sga.pucminas.br, humberto@pucminas.br,

Abstract. *The issue of fake news has garnered significant attention, with studies and media examining how and why such content spreads. However, many still believe fake news is confined to social networks, particularly during election periods, which is not the case. This study focuses on communication targeting children and adolescents on platforms like YouTube, where misleading information can influence their cognitive and critical development. Through sentiment analysis, topic analysis, and semantic analysis, the application demonstrated its effectiveness in using AI to detect misleading content, showing that fake news titles have a greater negative emotional impact on this audience. This highlights the need for protective tools to mitigate such effects and provide parents with automated fact-checking support.*

Resumo. *A questão das fake news tem recebido atenção significativa, com estudos e a mídia examinando como e por que esse conteúdo se espalha. No entanto, muitos ainda acreditam que as fake news estão restritas às redes sociais, especialmente durante o período eleitoral, o que não é um fato. Este estudo foca na comunicação direcionada às crianças e adolescentes em plataformas como o YouTube, onde informações enganosas podem influenciar seu desenvolvimento cognitivo e crítico. Por meio de análise de sentimentos, análise de tópicos e análise semântica, a aplicação comprovou sua eficácia ao usar IA para detectar conteúdos enganosos e demonstrou que títulos com fake news geram maior impacto emocional negativo nesse público, destacando a necessidade de ferramentas protetivas para reduzir esse impacto e oferecer suporte aos pais por meio de fact-checking automatizado.*

1. Introdução

A crença em fake news é influenciada por diversos fatores, incluindo a tendência das pessoas em aceitar informações que confirmem suas crenças pré-existentes

[Cunha Filho et al. 2023]. Além disso, a rápida disseminação de informações nas redes sociais, muitas vezes sem verificação de fontes confiáveis, contribui significativamente para a propagação de desinformação, com impactos especialmente prejudiciais no desenvolvimento social de crianças [Vartiainen et al. 2023]. A Sociedade Brasileira de Pediatria alerta para a necessidade de monitorar o uso de dispositivos eletrônicos por crianças e adolescentes, ressaltando a importância de proteger seu desenvolvimento saudável [Sociedade Brasileira de Pediatria 2024].

A dificuldade em distinguir fontes confiáveis, aliada à falta de tempo e viés cognitivo, aumenta a suscetibilidade de crianças e adolescentes à desinformação [Walsh and Johnson 2023]. Redes sociais como o YouTube expõem esse público vulnerável a informações enganosas, priorizando o engajamento em detrimento da veracidade. Estudos mostram que a exposição precoce à desinformação impacta negativamente o desenvolvimento cognitivo e crítico dos jovens [Lai 2024].

Este trabalho analisa o impacto de conteúdos com características de fake news no YouTube voltados para o público jovem. A metodologia inclui a análise de transcrições e comentários de vídeos com títulos enganosos e não enganosos, aplicando algoritmos de análise de sentimentos, tópicos e semântica. Os resultados demonstram que títulos enganosos geram maior impacto emocional negativo em crianças e adolescentes, reforçando a necessidade de tecnologias baseadas em inteligência artificial para combater a desinformação.

As seções seguintes deste artigo estão organizadas de forma que a Seção 2 apresenta e relaciona os trabalhos da literatura que abordam o tema deste estudo e a Seção 3 descreve a metodologia com foco na descrição dos requisitos. A Seção 4 discute a implementação, destacando o escopo escolhido e as tecnologias utilizadas. A Seção 5 relata os resultados obtidos com as avaliações realizadas e, por fim, a Seção 6 traz as considerações finais.

2. Revisão de Literatura

"A Identificação de Fake News" é um tema que tem recebido muita atenção com inúmeros artigos e pesquisas tentando traçar uma causa principal e um problema central – cada autor traça suas próprias conclusões. A questão das "fake news" [Lazer et al. 2018] é definida como informações fabricadas que imitam o conteúdo dos meios de comunicação em forma, mas não em processo organizacional ou intenção. Essas notícias falsas são criadas sem os padrões editoriais que garantem a precisão e credibilidade da informação, diferenciando-se claramente do jornalismo legítimo. Os mesmos autores enfatizam a urgência de um novo sistema de salvaguardas para enfrentar notícias falsas, investigando a vulnerabilidade de indivíduos e instituições e seu impacto na sociedade.

Ademais, esse tema tem recebido atenção significativa de pesquisadores e educadores, especialmente no que diz respeito à vulnerabilidade de crianças e adolescentes. Essa faixa etária, por estar em desenvolvimento cognitivo e emocional, é considerada particularmente suscetível a acreditar e disseminar informações falsas, uma vez que pode não ter ainda desenvolvido habilidades críticas de avaliação de fontes e conteúdo [Vartiainen et al. 2023]. Estudos mostram que crianças e adolescentes frequentemente carecem da capacidade de distinguir entre notícias reais e falsas, o que pode ter implicações sérias para sua formação social e política [Xu et al. 2022].

Paralelamente, a pesquisa na detecção semi-automática de fake news usando tecnologias de ponta, como aprendizado de máquina e mineração de dados, mostra avanços promissores. Tais métodos buscam analisar padrões de propagação, características linguísticas e a credibilidade das fontes para classificar e filtrar conteúdos não confiáveis de forma eficiente [Garcia 2023, de Araújo 2024]. Esse corpo de trabalho não apenas ajuda a identificar fake news, mas também oferece fundamentação teórica para o desenvolvimento de ferramentas educativas e tecnológicas que possam ser utilizadas para proteger e educar os jovens usuários na era digital.

Por fim, outra fundamentação teórica extremamente importante aborda a detecção automática de notícias falsas em português, destacando as dificuldades associadas à falta de conjuntos de dados rotulados em idiomas que não o inglês [Silva et al. 2020]. Os autores exploram estratégias de classificação, como *ensemble* e *stacking*, e discutem a influência do tamanho dos textos nos resultados de classificação. Os resultados mostram que recursos linguísticos baseados em representações distribuídas de texto podem ser eficazes para identificar notícias falsas, embora haja espaço para melhorias, especialmente em textos curtos. Além disso, destaca-se o papel crucial das plataformas de fact-checking, que não apenas auxiliam na validação de informações, mas também fornecem conjuntos de dados valiosos para treinar modelos de aprendizado de máquina. Essas iniciativas servem como um ponto de partida essencial para o desenvolvimento de métodos automatizados, contribuindo para a conscientização pública e o combate à disseminação de desinformação.[Vladika and Matthes 2023]

3. Metodologia

Nesta seção, será apresentada a metodologia adotada para o desenvolvimento da aplicação proposta, que envolve a detecção de fake news em títulos de vídeos no YouTube. A metodologia foi organizada em etapas para facilitar a compreensão do processo de análise, que inclui desde a elicitação de requisitos até a aplicação de técnicas específicas de análise textual e visual.

Para ilustrar o fluxo de trabalho, a Figura 1 apresenta um diagrama desenvolvido

na plataforma Canva, identificando os principais passos e subtarefas do processo metodológico. O diagrama destaca as etapas de captura de vídeos, extração da transcrição dos vídeos, aplicação de algoritmos de análise de sentimento, análise de tópicos e análise semântica, além da comparação com conteúdos sem fake news, visando identificar diferenças e impactos.

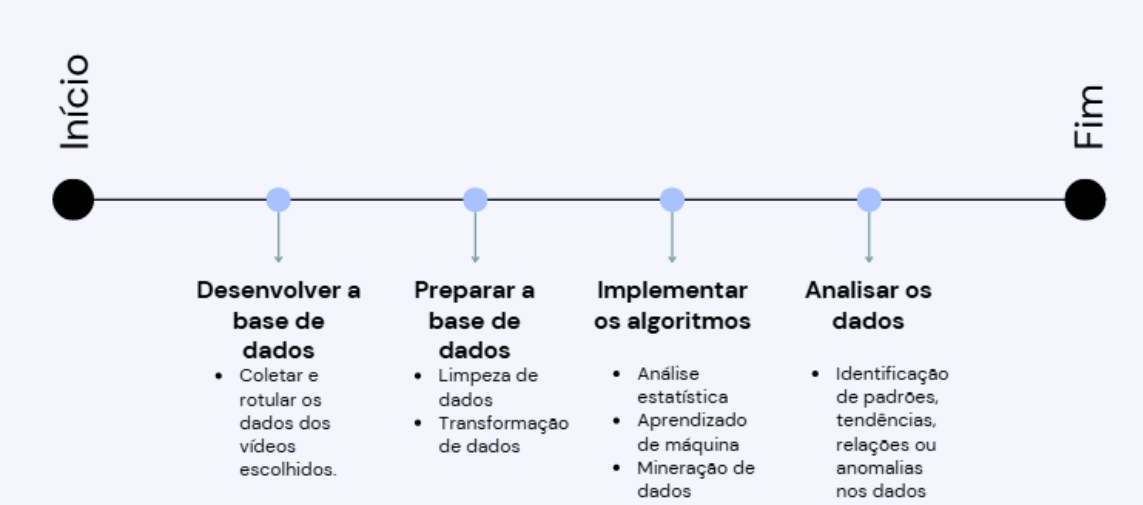


Figura 1. Diagrama da Metodologia.

3.1. Elicitação de Requisitos

A elicitação de requisitos foi realizada com base em uma comparação entre aplicações desenvolvidas em contextos similares de detecção , aliado a uma análise dos objetivos específicos que se deseja alcançar com o artigo e o método proposto. Essa etapa buscou identificar quais funcionalidades seriam essenciais para a aplicação atender aos objetivos de análise de fake news no contexto do público jovem.

3.2. Requisitos Funcionais

1. **Detecção e Análise de Conteúdo:** Capacidade de analisar automaticamente textos, imagens e vídeos para identificar possíveis fake news. Utilizar técnicas de processamento de linguagem natural e visão computacional.
2. **Relatório de Análise:** Geração de um relatório detalhado sobre a veracidade do conteúdo, explicando os motivos da classificação como verdadeiro ou falso.
3. **Análise de Sentimentos:** Análise de sentimentos em vídeos com fake news para comparação com vídeos sem fake news, a fim de identificar o impacto emocional negativo nos espectadores.

3.3. Requisitos Não Funcionais

1. **Desempenho:** A aplicação deve processar solicitações de verificação rapidamente, mesmo sob carga pesada.
2. **Notificações e Alertas:** Envio de alertas quando um conteúdo altamente compartilhado é identificado como fake news.
3. **Suporte Multilíngue:** Capacidade de analisar e verificar conteúdo em múltiplos idiomas.

4. Implementação

Nesta seção, serão detalhadas a escolha do escopo do projeto e as diferentes tecnologias utilizadas no desenvolvimento do modelo. As tecnologias serão apresentadas na ordem em que foram implementadas na aplicação.

4.1. Definição do Escopo

O primeiro passo da implementação foi definir o escopo do sistema. Foram consideradas diversas possibilidades de plataformas, entretanto, como o objetivo deste estudo é a identificação de fake news com foco em crianças e adolescentes, optou-se por concentrar os esforços na plataforma em que a maior parte desse público passa a maior parte do tempo: o **YouTube**. Segundo um estudo recente da Common Sense Media, crianças e adolescentes passam, em média, mais de uma hora por dia consumindo vídeos no YouTube, o que destaca a importância de monitorar conteúdos acessíveis a essa faixa etária na plataforma [Common Sense Media 2023]. A escolha de focar em títulos de vídeos do YouTube que contêm *leves* fake news, ao invés de desinformação evidente ou completa, é estratégica por diversas razões. Leves fake news referem-se a títulos que, embora não sejam completamente falsos, exageram, distorcem ou apresentam informações de maneira tendenciosa, com o objetivo de atrair cliques (prática conhecida como *clickbait*) ou moldar a percepção do espectador [Munger et al. 2018]. Essa abordagem mais sutil muitas vezes escapa de sistemas automáticos de detecção de fake news e requer uma análise mais cuidadosa e complexa, o que torna esse estudo especialmente relevante [Mowar et al. 2021].

O primeiro benefício de estudar esse tipo de desinformação é a sua alta prevalência. Vídeos com títulos levemente enganosos são comuns no YouTube, especialmente em conteúdos sensacionalistas ou de cunho opinativo. Isso se deve, em parte, à pressão para maximizar visualizações e engajamento na plataforma. O artigo de Papadomou [Papadamou 2021] analisa a prevalência de conteúdo problemático no YouTube, incluindo vídeos com títulos enganosos, e discute como a busca por engajamento influencia a disseminação de desinformação na plataforma.

Outro ponto crucial é a dificuldade técnica associada à identificação de fake news sutis. Ao contrário de alegações claramente falsas, como teorias da conspiração já desacreditadas, as leves fake news exigem métodos mais sofisticados de análise, envolvendo compreensão de contexto, ambiguidade semântica e análise de intenção [Zhou et al. 2023]. Isso proporciona um campo de estudo valioso para avançar as técnicas de Processamento de Linguagem Natural (NLP) e aprendizado de máquina, desafiando os modelos a reconhecerem padrões complexos de manipulação informacional.

4.2. Coleta e Construção da Base de Dados

A base de dados para a aplicação de detecção de fake news em títulos de vídeos do YouTube foi construída utilizando um *crawler* em Python, desenvolvido para automatizar a coleta de dados. Foram utilizadas palavras-chave como **"24 Horas sem ser visto", "desafio impossível", "segredo revelado"e "você não vai acreditar"**, associadas a temas sensíveis, como **desafios perigosos e exageros sensacionalistas**.

Os vídeos foram coletados de influenciadores populares entre o público infantojuvenil, como **Enaldinho, Natan por Aí, Luluca, Luccas Neto e Geleia**, devido à vulnerabilidade desse público à desinformação. Títulos como *"Você não vai acreditar no que encontrei!"* foram selecionados como exemplos de leve fake news, enquanto vídeos com títulos factuais foram capturados sem o uso dessas palavras-chave e rotulados manualmente.

O *crawler* foi configurado para interagir com a *API do YouTube Data v3*[1], coletando informações detalhadas de vídeos públicos, como título, descrição, estatísticas de engajamento (visualizações, *likes* e *dislikes*), além de dados temporais, como a data de publicação, e metadados relacionados ao canal de origem. Para enriquecer ainda mais o conjunto de dados, o *crawler* também extraiu as transcrições dos vídeos e os comentários associados, permitindo uma análise aprofundada das interações entre criadores e espectadores.

Uma parte fundamental do funcionamento do *crawler* é sua capacidade de gerenciar eficientemente os limites da *API*, implementando controle de taxa (*rate limiting*) para evitar exceder o número máximo de consultas diárias. Além disso, o uso de múltiplas chaves de API foi empregado para aumentar a eficiência da coleta. Estratégias como filtros de datas, número de visualizações e categorias de conteúdo garantiram a diversidade e a representatividade dos dados coletados.

Após a coleta inicial, uma etapa crítica foi a rotulagem dos títulos dos vídeos, realizada manualmente para identificar se cada título continha ou não informações enganosas.

[1] `https://developers.google.com/youtube/v3?hl=pt-br`

Um critério válido utilizado para a rotulagem foi a presença de títulos que, embora não fossem totalmente falsos, utilizavam **exageros, informações sensacionalistas, ambiguidades ou omissões intencionais** para atrair a atenção do público.

No entanto, vale destacar que a identificação dessas fake news possui um alto grau de **subjetividade**, uma vez que a percepção do que constitui leve desinformação pode variar conforme o contexto, o tom do vídeo e a interpretação individual. Por isso, a rotulagem envolveu uma análise criteriosa do título em conjunto com o contexto do vídeo.

4.3. Dados da Coleta

A Tabela 1 apresenta os principais dados relacionados à coleta de informações para análise de vídeos, incluindo o período da coleta, a quantidade de vídeos analisados, a quantidade de canais de origem e a quantidade de comentários coletados.

Tabela 1. Dados da Coleta

Descrição	**Valores**
Período da Coleta	12/11 a 19/11
Quantidade de Vídeos	250
Quantidade de Canais	5
Quantidade de Comentários	1.645.556

4.4. Tratamento dos Dados

No intuito de adequar os dados brutos, foi necessário submetê-los aos procedimentos de pré-processamento descritos a seguir:

1. **Remoção de *stop words* e pontuações:** Foram removidas palavras comuns que não carregam valor semântico relevante para a classificação, como artigos e preposições, além de pontuações, símbolos especiais e números. Isso permitiu reduzir o ruído nos textos e focar em termos mais significativos.
2. **Tokenização:** Os textos foram segmentados em unidades menores (tokens), permitindo uma análise mais granular dos dados. Esta técnica facilitou a aplicação de outros métodos de pré-processamento e a transformação dos textos em representações numéricas.
3. **Remoçao de risadas e caracteres repetidos:** Esses termos foram eliminidos devido a sua quantidade e para não dominarem a análise tópica (e.g., `"kkkkk"`, `"hahaha"`) e (e.g., `"looooool"` para `"lol"`).
4. **Conversão para minúsculas:** Todos os textos foram convertidos para letras minúsculas para garantir consistência e evitar a duplicação de palavras devido à capitalização. Isso ajudou a unificar as palavras com a mesma raiz que poderiam ser consideradas diferentes pela aplicação.

Essas técnicas de pré-processamento foram essenciais para limpar e preparar os dados, tornando-os adequados para a aplicação de algoritmos de aprendizado de máquina. Os pacotes e bibliotecas que foram utilizados são: *Pandas* , *string* , *unicodedata* e *nltk*.

4.5. Aplicação de algoritmos de análise de tópicos

Após a construção da base de dados, foram aplicados métodos de Machine Learning para realizar a análise de tópicos nos dados pré-processados. Para isso, foram utilizadas técnicas de Processamento de Linguagem Natural (NLP), que transformam o conteúdo textual em representações numéricas compreensíveis pelos modelos de aprendizado. O modelo escolhido para a análise de tópicos foi o **BERTopic**[2], uma técnica avançada de NLP que combina a representação contextual de palavras do BERT com algoritmos de agrupamento para identificar tópicos latentes nos dados.

O BERTopic destaca-se por sua capacidade de criar representações temáticas altamente coerentes, utilizando os vetores gerados pelo BERT para capturar tanto o contexto anterior quanto o posterior de cada palavra em uma sentença. Além disso, esse modelo responde de maneira eficiente a textos em português brasileiro, possibilitando uma análise mais detalhada e contextual dos tópicos presentes nos títulos, comentários e transcrições dos vídeos. Isso permite revelar nuances sutis que podem estar relacionadas à presença de fake news [Grootendorst 2022].

Diferentemente das abordagens mais tradicionais, como o *Latent Dirichlet Allocation* (LDA), que se baseiam exclusivamente na frequência de palavras, o BERTopic utiliza vetores de alta dimensionalidade para codificar o significado contextual de cada palavra em relação à sentença completa.

Durante o processo de análise, o BERTopic ajusta os parâmetros de agrupamento com base na similaridade semântica dos vetores, otimizando sua capacidade de identificar tópicos consistentes e representativos. Para avaliar a qualidade dos tópicos gerados, foram utilizadas métricas como coerência temática e análise qualitativa. Os resultados demonstraram que o BERTopic apresenta excelente desempenho na identificação de padrões temáticos relacionados a fake news e manipulações leves nos vídeos analisados.

4.6. Aplicação de algoritmos de análise de sentimentos

A etapa seguinte é a identificação dos sentimentos gerados por esses vídeos e, para isso, será utilizado um algoritmo de análise de sentimentos robusto, capaz de fornecer uma visão detalhada e precisa.

Inicialmente, foram testadas as ferramentas **VADER** e **TextBlob**, que possuem características importantes na análise de sentimentos em textos curtos e mais genéricos. No

[2]`https://maartengr.github.io/BERTopic/index.html`

entanto, ambas apresentaram limitações, principalmente na análise de frases complexas, sentimentos implícitos e na detecção de nuances emocionais.

Por fim, os modelos de **Transformers da Hugging Face**[3], como o BERT ou o DistilBERT, mostraram-se superiores. Essa escolha se deve à utilização de um modelo pré-treinado em comentários do Twitter em português, o que garante uma alta eficácia na análise de sentimentos nesse idioma. Além disso, esses modelos possuem capacidade avançada de captar sentimentos que dependem do contexto ao longo de frases ou parágrafos inteiros, adaptando-se melhor à complexidade dos discursos presentes nos vídeos analisados [Wolf et al. 2020].

5. Resultados

Nesta seção, serão detalhadamente apresentados e analisados os resultados obtidos a partir do modelo aplicado sobre as transcrições e os comentários dos vídeos coletados. O objetivo é destacar os principais achados e evidências que surgiram durante a análise, oferecendo uma visão abrangente do desempenho do modelo e dos padrões identificados nos dados. Além disso, serão discutidos os aspectos relevantes, como os tópicos predominantes nas transcrições, os sentimentos expressos nos comentários e como essas informações se correlacionam com as características dos vídeos analisados. Por fim, serão exploradas as implicações desses resultados, ressaltando sua relevância para a compreensão do impacto dos títulos com leves fake news ou clickbaits na percepção e interação do público.

5.1. Análise de Tópicos

Os resultados obtidos indicam que vídeos com leves fake news tendem a destacar tópicos de elevado apelo emocional e sensacionalismo, concentrando-se em elementos como ”desafio”, ”mistério”e ”aventura”. A Figura 2 ilustra os resultados da análise de tópicos aplicada nas transcrições desses vídeos, o eixo y do gráfico contém os tópicos e o eixo x a respectiva proporção desses tópicos na transcrição, reafirmando que a exploração de temas com alta carga emocional é uma estratégia recorrente nesse tipo de conteúdo.

[3]`https://huggingface.co/docs/transformers/index`

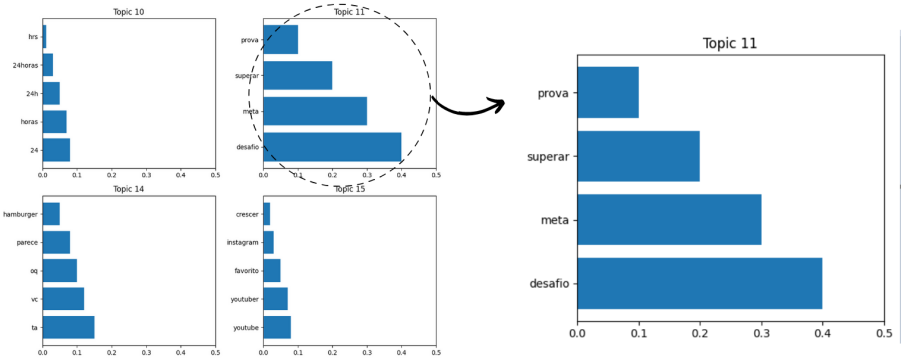


Figura 2. Análise de tópicos das transcrições dos vídeos com leves fake news no título.

Adicionalmente, a análise de tópicos dos comentários dos vídeos com títulos contendo leves fake news revelou *insights* significativos. A Figura 3 destaca a predominância do tópico relacionado a ”mentiras”nos comentários, sugerindo que o público-alvo, atraído inicialmente pelo título desinformativo, frequentemente se sente enganado, expressando tal percepção por meio de comentários. Essa conclusão é corroborada pela análise de sentimentos, a ser discutida na próxima subseção.

Além disso, a Figura 4 reforça a relevância do tópico ”mentiras”, evidenciada pela visualização de uma nuvem de palavras baseada nos tópicos mais frequentes presentes nos comentários.

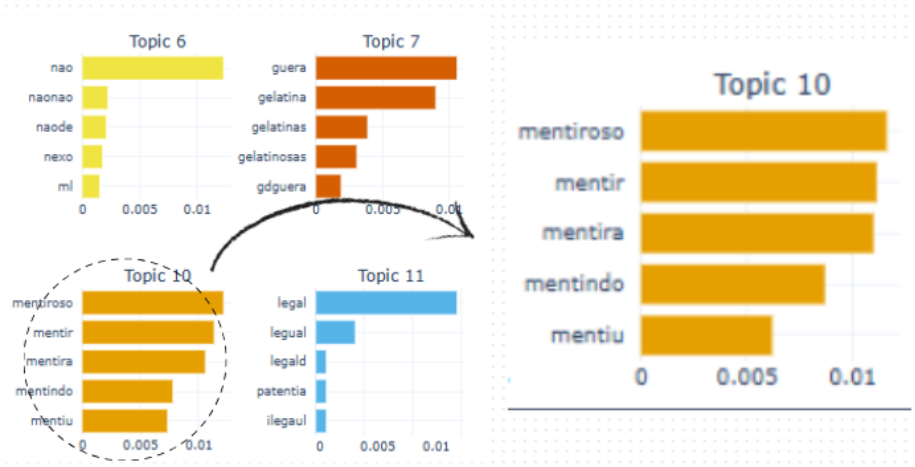


Figura 3. Análise de tópicos dos comentários dos vídeos com leves fake news no título.

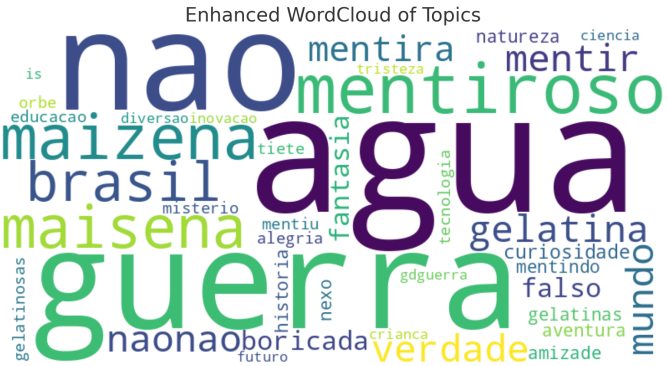


Figura 4. WordCloud da análise de tópicos dos comentários dos vídeos com leves fake news no título.

Em contrapartida, vídeos classificados como verdadeiros exibiram uma frequência maior de tópicos relacionados à educação e informação, apontando uma possível distinção nas intenções dos criadores de conteúdo e no impacto direcionado ao público jovem. Nos comentários, também é possível ver que o tópico de mentiras não está presente como pode ser visto na Figura 5, em que os tópicos estão no eixo y e sua respectiva proporção no eixo x do gráfico.



Figura 5. Análise de tópicos dos comentários dos vídeos sem fake news no título.

5.2. Análise de Sentimentos

A análise de sentimentos dos comentários revelou descobertas importantes sobre as percepções do público em relação aos vídeos com títulos contendo leves fake news. Os

resultados foram agrupados em três categorias principais de sentimentos: positivo, neutro e negativo.

5.2.1. Exemplos de Comentários

Para ilustrar os resultados, a Tabela 2 apresenta exemplos de comentários classificados de acordo com o sentimento predominante. O objetivo dessa tabela é demonstrar a eficácia do modelo na captura da essência dos sentimentos expressos pelos usuários, destacando as diferenças nas características linguísticas e emocionais dos comentários.

Tabela 2. Exemplos de Comentários por Sentimento

Sentimento	Exemplo de Comentário
Positivo	Eu amei o vídeo, sou sua fã!
Neutro	Eu sou de 2024.
Negativo	Conteúdo ruim com clickbait!

5.2.2. Distribuição de Sentimentos

A Figura 6 apresenta a distribuição dos sentimentos nos comentários de vídeos com e sem fake news. No gráfico à esquerda, destaca-se a predominância de comentários *neutros*, seguidos por negativos e, em menor proporção, positivos, sugerindo insatisfação do público com conteúdos enganosos. No gráfico à direita, os comentários *neutros* também predominam, mas há uma maior proporção de positivos em relação aos negativos, evidenciando a influência da desinformação na percepção pública.Essa diferença reforça a relação entre a presença de desinformação intencional e a percepção negativa do público.

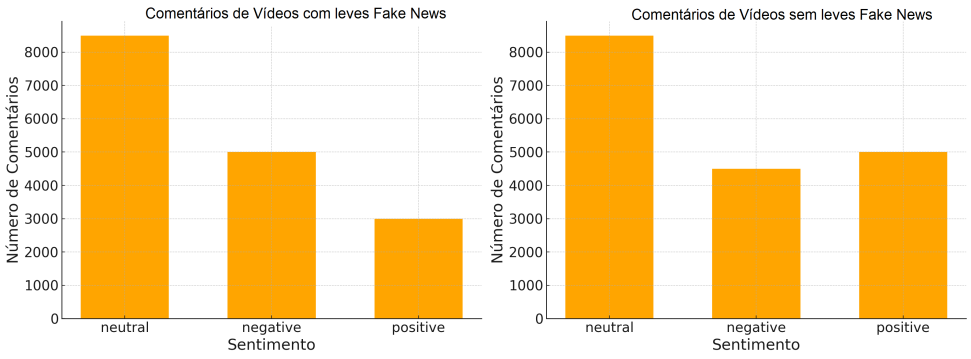


Figura 6. Distribuição de sentimentos dos comentários.

6. Conclusões e Trabalhos Futuros

Este trabalho apresentou o desenvolvimento de uma aplicação como parte de uma pesquisa voltada à identificação de fake news em vídeos no YouTube, com foco no público infanto-juvenil. A aplicação demonstrou sua eficácia ao integrar técnicas de análise de sentimentos, análise de tópicos e semântica, utilizando inteligência artificial para detectar e comparar conteúdos com e sem fake news em títulos de vídeos. Os resultados obtidos indicaram que vídeos com títulos levemente enganosos exercem um impacto emocional negativo maior sobre os espectadores, especialmente crianças e adolescentes, reforçando a importância de ferramentas destinadas à proteção desse público.

A pesquisa também evidenciou a viabilidade técnica da aplicação, que apresentou um *pipeline* funcional e resultados consistentes. Contudo, algumas limitações foram identificadas, como a dependência da API do YouTube, que restringe a coleta de dados em larga escala, e o escopo do trabalho, limitado a análises baseadas em conteúdos de apenas alguns youtubers e influenciadores.

Para trabalhos futuros, seria interessante expandir a pesquisa com a coleta de um volume maior de dados, abrangendo diferentes perfis de criadores de conteúdo e explorando métodos complementares de análise que permitam ampliar o entendimento sobre os impactos psicológicos e sociais das fake news em jovens. Além disso, seria valioso investigar como fake news em conteúdos digitais afetam crianças e adolescentes neurodivergentes, buscando identificar padrões específicos de impacto emocional e cognitivo nesse público.

Referências

Common Sense Media (2023). The common sense census: Media use by tweens and teens, 2023.

Cunha Filho, M., Carvalho, P., and Carvalho, S. (2023). O que sabemos sobre fake news? uma revisão bibliográfica sobre definições, e sobre os aspectos psicológicos e políticos do fenômeno. *Revista Quaestio Iuris*.

de Araújo, J. V. (2024). Detecção de fake news: uma análise comparativa.

Garcia, G. L. (2023). Detecção de fake news utilizando aprendizado de máquina. Master's thesis, Universidade Estadual Paulista (Unesp), Bauru, SP, Brasil.

Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*.

Lai, M. S. K. (2024). The impact of social media misinformation on adolescents' cognitive perceptions and belief systems. *Scholar of Tomorrow*.

Lazer, D. M. J. et al. (2018). The science of fake news. *Science*, 359:1094–1096.

Mowar, P., Jain, M., Goel, R., and Vishwakarma, D. K. (2021). Clickbait in youtube prevention, detection and analysis of the bait using ensemble learning.

Munger, K., Luca, M., Nagler, J., and Tucker, J. (2018). The effect of clickbait. *Verfügbar unter https://rubenson. org/wp-content/uploads/2018/09/munger-tpbw18. pdf, letzter Zugriff*, 26:2020.

Papadamou, K. (2021). Characterizing abhorrent, misinformative, and mistargeted content on youtube. *arXiv preprint arXiv:2105.09819*.

Silva, R. M., Santos, R. L. S., Almeida, T. A., and Pardo, T. A. S. (2020). Towards automatically filtering fake news in portuguese. *Expert Systems with Applications*, 146:113199.

Sociedade Brasileira de Pediatria (2024). Sociedade brasileira de pediatria atualiza orientações para crianças e adolescentes na era digital.

Vartiainen, H., Kahila, J., Tedre, M., Sointu, E., and Valtonen, T. (2023). More than fabricated news reports: Children's perspectives and experiences of fake news. *Journal of Media Literacy Education*, 15(2):17–30.

Vladika, J. and Matthes, F. (2023). Scientific fact-checking: A survey of resources and approaches. *arXiv preprint arXiv:2305.16859*.

Walsh, R. and Johnson, P. (2023). The rise and impact of misinformation and fake news on digital youth: A critical review. *Journal of Media Literacy Education*, 15(2):12–30.

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., et al. (2020). Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations*, pages 38–45.

Xu, S., Shtulman, A., and Young, A. G. (2022). Can children detect fake news? In *Proceedings of the Annual Meeting of the Cognitive Science Society*, volume 44.

Zhou, X., Li, J., Li, Q., and Zafarani, R. (2023). Linguistic-style-aware neural networks for fake news detection. *arXiv preprint arXiv:2301.02792*.